TÜBİTAK 2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEKLEME PROGRAMI

Başvuru formunun Arial 9 yazı tipinde, her bir konu başlığı altında verilen açıklamalar göz önünde bulundurularak hazırlanması ve ekler hariç toplam 20 sayfayı geçmemesi beklenir (Alt sınır bulunmamaktadır). Değerlendirme araştırma önerisinin bilimsel niteliği, yöntemi, proje yönetimi ve yaygın etkisi başlıkları üzerinden yapılacaktır.

ARAŞTIRMA ÖNERİSİ FORMU

2025 Yılı

1. Dönem Başvurusu

2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEKLEME PROGRAMI ARAŞTIRMA ÖNERİSİ FORMU

A. GENEL BİLGİLER

Başvuru Sahibinin Adı Soyadı: Ahmet GÜN
Araştırma Önerisinin Başlığı: İşletmelerde Çoklu Yapay Zekâ Modelleriyle Açıklanabilir Müşteri Kaybı Tahminleme ve Karar Destek Prototipinin Oluşturulması
Danışmanın Adı Soyadı: Yeşim ÜLGEN SÖNMEZ
Araştırmanın Yürütüleceği Kurum/Kuruluş: Fırat Üniversitesi

ÖZET

Araştırma önerisi özetinin (1) bilimsel nitelik; (2) yöntem; (3) proje yönetimi ve (4) yaygın etki hakkında bilgileri kapsaması beklenir. Bu bölümün en son yazılması önerilir.

20.yüzyılın ikinci yarısından itibaren hızla büyüyen rekabet ortamı, kurumların müşterilerini elde tutma stratejilerinde veri temelli çözümler geliştirmeye yöneltmiştir. Özellikle telekomünikasyon sektöründe müşteri kaybı (churn) analizi, işletmelerin sürdürülebilirliği için stratejik bir unsur haline gelmiştir. Ancak, mevcut yapay zekâ tabanlı tahmin modelleri çoğu zaman yalnızca yüksek doğruluk oranlarına odaklanmakta, bu tahminlerin neden ve nasıl oluştuğunu açıklamakta yetersiz kalmaktadır. Müşteri kaybı tahmini gibi kritik karar destek sistemlerinde, makine öğrenmesi algoritmalarının "karanlık kutu" doğası kabul edilemez bir risk taşımaktadır. Her bir tahmini bir olasılık değerinden öte, XAI (Açıklanabilir Yapay Zekâ) prensipleriyle yorumlanabilir bir nedensellik zinciri olarak ele almalı; böylece karmaşık modelleri, karar mekanizmalarını şeffaflaştıran, güvenilir ve denetlenebilir sistemler haline getirmeliyiz. Bu vizyon doğrultusunda projemizin misyonu yalnızca modellerin doğruluğunu artırmak değil, aynı zamanda tahminsel modellemede güven ve anlayışın özünü yeniden tanımlamaktır.

Bu çalışmada, Kaggle Telco Customer Churn veri seti üzerinde hem Makine Öğrenmesi (ML) hem de Derin Öğrenme (DL) tabanlı modeller kullanılacaktır. Bu sayede her modelin güçlü yönü devreye alınarak tahmin performansı artırılacaktır. İlk aşamada veri temizleme ve ön işleme işlemleri tamamlanacak, ardından Lojistik Regresyon, Random Forest, KNN, SVM ve XGBoost modelleri eğitilecektir. Modellerin performansı yalnızca doğruluk (Accuracy) üzerinden değil; aynı zamanda F1-Score, Precision (Kesinlik), Recall (Duyarlılık) ve AUC (Area Under Curve) gibi istatistiksel metriklerle de değerlendirilecektir. Bu kapsamlı değerlendirme, modellerin sadece genel doğruluklarını değil, aynı zamanda dengesiz veri dağılımlarındaki tahmin güvenirliklerini de ortaya koyacaktır. En yüksek genel başarıya sahip model seçilerek performansı derin öğrenme modeli ile karşılaştırılacaktır.

Projede özgün olarak, modellerin sadece sonuçları değil, karar mekanizmaları da derinlemesine incelenecektir. Bu amaçla, Açıklanabilir Yapay Zekâ (XAI) alanında öne çıkan bir yöntem olan SHAP (SHapley Additive exPlanations) kullanılacaktır. SHAP, işbirlikçi oyun teorisine dayalı olarak her bir özelliğin modele katkısını adil biçimde ölçer ve böylece “kara kutu” olarak adlandırılan yapay zekâ modellerinin iç işleyişini görünür hale getirir. “Kara kutu” kavramı, modelin yüksek doğrulukla sonuç üretmesine rağmen bu sonuçların nasıl elde edildiğinin insan tarafından anlaşılamadığı durumu ifade eder. SHAP yöntemi sayesinde bu şeffaflık sorunu ortadan kaldırılarak, müşteri kaybını en çok etkileyen faktörler açıkça görülebilecek ve modelin karar mantığı insan gözüyle yorumlanabilir hale gelecektir.

Son aşamada, en başarılı ve açıklanabilir model Streamlit kütüphanesi kullanılarak etkileşimli bir prototipe dönüştürülecektir. Bu sayede kullanıcılar, tahmin sonuçlarını görsel olarak inceleyebilecek, SHAP analizleriyle her bir değişkenin etkisini interaktif biçimde gözlemleyebilecektir. Sonuç olarak, bu proje yalnızca yüksek doğrulukta tahmin yapan bir model sunmayı değil, aynı zamanda kararların ardındaki mantığı da görünür kılmayı hedeflemektedir. Böylece telekom müşteri kaybı tahmini alanında hem bilimsel hem de pratik düzeyde açıklanabilir yapay zekâ temelli yenilikçi bir çözüm ortaya konacaktır.

Anahtar Kelimeler: Derin Öğrenme, Kara Kutu, Makine Öğrenmesi, SHAP, XAI

1. ARAŞTIRMA ÖNERİSİNİN BİLİMSEL NİTELİĞİ

1.1. Konunun Önemi ve Araştırma Önerisinin Bilimsel Niteliği

Araştırma önerisinde ele alınan konunun kapsamı, sınırları ve önemi ortaya konulur. Araştırma önerisi kapsamında yapılacak çalışmalarla literatürdeki hangi eksikliğin nasıl giderileceği veya hangi soruna nasıl bir çözüm getirileceği ilgili literatüre atıfla açıklanarak araştırma önerisinin bilimsel niteliği ortaya konulur. Araştırma sorusu ve varsa hipotez(ler)i tanımlanır.

Projenin konusu, 12. Kalkınma Planı ve 2030 Sanayi ve Teknoloji Stratejisi'nde yer alan kritik teknoloji alanları ile öncelikli Ar-Ge ve yenilik konuları ile ilişkili ise, ilişkilendirilme sebebi ve ilgili alana sağlayacağı yararlar açıklanmalıdır.

Konunun Kapsamı ve Önemi: Bu araştırma, kapsam olarak işletmelerin sürdürülebilir büyümesi için kritik öneme sahip olan müşteri kaybı (customer churn) sorununa proaktif bir yaklaşımla çözüm üretmeyi hedeflemektedir. Artan rekabet koşulları, işletmelerin yalnızca yeni müşteri kazanımına değil, mevcut müşterileri elde tutmaya da stratejik önem vermesini zorunlu kılmıştır. Özellikle telekomünikasyon gibi rekabetin yoğun yaşandığı sektörlerde, yeni bir müşteri kazanma maliyetinin mevcut bir müşteriyi elde tutma maliyetinden daha fazla olduğu yapılan çalışmalarda vurgulanmıştır [1]. Dolayısıyla müşteri kaybının erken tespiti ve önlenmesi, işletmelerin finansal sürdürülebilirliği kadar, marka itibarı ve müşteri sadakatini koruma açısından da proaktif bir stratejik gereklilik haline gelmiştir [2]. Bu projenin temel amacı, telekomünikasyon sektöründeki müşterilerin davranışsal ve demografik özelliklerini kullanarak, şirketten ayrılıp ayrılmayacaklarını tahmin edebilen ve bu tahminlerin nedenlerini açıklayabilen modeller geliştirmektir. Böylece yalnızca "kim gidecek" sorusuna değil, aynı zamanda "neden gidecek" sorusuna da yanıt aranacaktır. Çünkü bir işletme için bir müşterinin neden ayrıldığı bilgisi, gelecekte benzer müşteri kayıplarını önlemenin anahtarıdır.

Literatürdeki Eksiklik ve Bilimsel Nitelik (Özgün Değer): Son yıllarda Makine Öğrenmesi (ML) ve Derin Öğrenme (DL) yöntemleri müşteri kaybı tahmininde yaygın olarak kullanılmaktadır. Ancak literatürdeki çalışmaların büyük çoğunluğu yalnızca modelin doğruluk oranına (accuracy) odaklanmaktadır [2, 3, 4] ancak; karar süreçlerinin açıklanabilirliğini ihmal etmektedir. Oysa işletme yöneticileri için yüksek doğruluk oranına sahip ama karar mantığı anlaşılmayan bir modelin değeri sınırlıdır. Çünkü bu tür "kara kutu" (black box) modeller, tahmin sonuçlarının nedenlerini açıklamadığı için stratejik kararların alınmasını zorlaştırmaktadır [3, 4]. Bu amaçla, Açıklanabilir Yapay Zekâ (XAI) alanındaki en gelişmiş tekniklerden biri olan SHAP (SHapley Additive exPlanations) [4] yöntemi kullanılacaktır. İşbirlikçi oyun teorisine dayanan SHAP, her bir özelliğin modelin tahminine olan katkısını adil bir şekilde ölçerek "kara kutu"yu anlaşılır hale getirir [5]. Bu proje, yalnızca klasik makine öğrenmesi modellerini değil, aynı zamanda *derin öğrenme (Deep Learning)* mimarilerini de kapsayarak literatürdeki açıklanabilirlik tartışmalarını ileri bir düzeye taşımayı hedeflemektedir. Özellikle Çok Katmanlı Algılayıcı (MLP) modelinin SHAP [6, 7, 8] yöntemiyle analiz edilmesi, genellikle kara kutu olarak görülen derin öğrenme modellerinin nasıl karar verdiğini aydınlatacaktır. Böylece, hem klasik ML hem de DL modelleri SHAP aracılığıyla karşılaştırılarak hangi yaklaşımın "daha iyi açıklanabilir" ve "daha eyleme geçirilebilir" çıktılar sunduğu bilimsel olarak ortaya konacaktır [9]. Bu yönüyle proje, yalnızca tahmin gücü yüksek bir model geliştirmeyi değil, aynı zamanda yöneticilerin güvenle kullanabileceği, açıklanabilir ve proaktif bir karar destek sistemi tasarlamayı amaçlamaktadır.

Prototipleme ve Kullanılacak Teknoloji: Analizlerin sonunda, geliştirilen model sonuçları interaktif bir web prototipi aracılığıyla sunulacaktır. Bu prototip, kullanıcıların bir müşterinin ayrılma olasılığını ve bu kararın arkasındaki nedenleri (örneğin yüksek fatura, kısa abonelik süresi gibi) görsel olarak inceleyebileceği şekilde tasarlanacaktır. Prototip geliştirmede Streamlit Kütüphanesi kullanılacaktır. Streamlit, veri bilimi çıktılarının (grafikler, tablolar, SHAP görselleri) web arayüzünde kolayca sunulmasına imkân tanıyan, modern ve dinamik bir framework'tür. Geleneksel masaüstü araçlarından Tkinter'a kıyasla çok daha hızlı prototipleme olanağı sağlar; ayrıca web tabanlı olması sayesinde çok kullanıcı tarafından aynı anda erişilebilir bir karar destek aracı sunar. Bu yönüyle Streamlit, hem akademik hem de endüstriyel uygulamalarda etkileşimli açıklanabilirlik sunmak için en uygun platformdur.

Bu çalışmanın Bilimsel ve Stratejik Katkı: Bu proje, klasik doğruluk odaklı modelleme anlayışını aşarak açıklanabilir yapay zekâ yaklaşımıyla "neden-sonuç ilişkilerini" ön plana çıkaracaktır. Böylece yalnızca teknik olarak güçlü değil, aynı zamanda karar vericiler için güvenilir, proaktif ve eyleme geçirilebilir sonuçlar üreten bir yapay zekâ sistemi oluşturulacaktır. Türkiye'nin 12. Kalkınma Planı ve 2030 Sanayi ve Teknoloji Stratejisi'nde vurgulanan "Yapay Zekâ", "Büyük Veri" ve "Dijital Dönüşüm" öncelikli alanlarıyla doğrudan uyumlu olan bu proje, ulusal dijital dönüşüm hedeflerine katkı sağlayacaktır. Ayrıca, müşteri kaybının ekonomik ve stratejik önemini merkeze alarak, işletmelerin rekabet gücünü artıracak veriye dayalı bir karar destek sistemi sunacaktır.

1.2. Amaç ve Hedefler

Araştırma önerisinin amacı ve hedefleri açık, ölçülebilir, gerçekçi ve ulaşılabilir nitelikte olacak şekilde yazılır.

Bu araştırmanın temel amacı, Kaggle platformunda yer alan Telco Customer Churn veri setini kullanarak müşteri kaybını tahmin edebilen bir yapay zekâ modeli geliştirmektir. Bu doğrultuda, veri seti üzerinde makine öğrenmesi ve derin öğrenme modelleri eğitilecek; elde edilen sonuçlar SHAP (SHapley Additive exPlanations) Kütüphanesi kullanılarak açıklanabilir hâle getirilecektir. Böylece, yöneticilerin bir müşterinin neden kaybedileceğini daha iyi anlamaları ve bu nedenlere yönelik önleyici stratejiler geliştirebilmeleri hedeflenmektedir.

Araştırmanın spesifik amaç ve hedefleri şu şekilde belirlenmiştir:

Amaç 1: Telekomünikasyon sektöründe müşteri kaybını (churn) önceden tahmin edebilen yapay zekâ tabanlı bir model

geliştirmek.

- **Hedef 1:** Kaggle platformundan alınan Telco Customer veri setini analiz ederek, makine öğrenmesi yöntemleriyle (Lojistik Regresyon, Random Forest, KNN, SVM, XGBoost) müşteri kaybı tahmin modelleri oluşturmak ve performanslarını karşılaştırmak.

Amaç 2: Müşteri kaybı tahmininde derin öğrenme yöntemlerinin etkinliğini incelemek.

- **Hedef 2:** Makine öğrenmesi sonuçlarından elde edilen en başarılı modeli temel alarak bir derin öğrenme (DL) modeli kurmak ve performans metrikleri (accuracy, precision, recall, F1-score) açısından karşılaştırmalı analiz yapmak.

Amaç 3: Modelin karar süreçlerinin açıklanabilirliğini artırmak.

- **Hedef 3:** Makine öğrenmesi ve derin öğrenme modellerine SHAP (SHapley Additive exPlanations) analizi uygulayarak, modelin hangi değişkenler aracılığıyla müşteri kaybı tahmininde bulunduğunu açıklamak ve karar şeffaflığını sağlamak.

Amaç 4: Kullanıcı dostu bir arayüz aracılığıyla modelin uygulanabilirliğini göstermek.

- **Hedef 4**: En yüksek doğruluk oranına sahip modeli kullanarak bir Streamlit tabanlı prototip uygulama geliştirmek, kullanıcıların müşteri verilerini girerek anında tahmin sonucu alabilecekleri bir sistem ortaya koymak.

Amaç 5: Proje çıktılarının sektörel faydasını ortaya koymak.

- **Hedef 5:** Elde edilen bulgular ışığında, telekomünikasyon firmalarının müşteri kaybını önleme stratejilerine yapay zekâ destekli bir çözüm önerisi sunmak ve müşteri sadakatini artırmaya yönelik veri temelli yaklaşımlar geliştirmek.

Amaç 6: Literatürdeki kara kutu problemine açıklık getirmek.

- **Hedef 6:** "Kara Kutu" problemini (makinenin verdiği sonuçların arkasındaki nedenin bilinmemesi) XAI tekniği olan SHAP ile açıklamak ve Streamlit Kütüphanesi ile kullanıcılara müşteri kaybı nedenlerini görselleştirerek sunmak.

2. YÖNTEM

Araştırmada uygulanacak yöntem ve araştırma tekniklerinin, amaç ve hedeflere ulaşmaya ne düzeyde elverişli olduğu ilgili literatüre atıf yapılarak ortaya konulur.

Yöntem bölümünün; araştırma tasarımı, bağımlı ve bağımsız değişkenler, istatistiksel yöntemler vb. unsurları içermesi gerekir. Araştırma önerisinde herhangi bir ön çalışma veya fizibilite yapıldıysa bunların sunulması beklenir. Araştırma önerisinde sunulan yöntemlerin çalışma takvimi ile ilişkilendirilmesi gerekir.

1. Kütüphanelerin Yüklenmesi ve Ortam Hazırlığı: Projenin ilk aşamasında Python tabanlı veri bilimi ve yapay zekâ kütüphaneleri kurulmuştur. Kullanılacak başlıca kütüphaneler şunlardır [10, 11, 12]:

- Pandas ve NumPy : Veri işleme ve istatistiksel analiz için,
- Matplotlib ve Seaborn: Görselleştirme için,
- Scikit-learn (sklearn): Makine öğrenmesi modellerinin uygulanması için,
- TensorFlow / Keras: Derin öğrenme modeli (MLP) kurulumu için [6],
- SHAP: Açıklanabilir yapay zekâ analizleri için [13],
- Streamlit: Sonuçların etkileşimli bir web arayüzünde görselleştirilmesi için kullanılmıştır.

2. Veri Setinin Temini ve İncelenmesi: Çalışmada kullanılan veri seti, "Kaggle Telco Customer Churn" veri setidir. Veri seti, bir telekomünikasyon firmasına ait müşteri bilgilerini (abonelik süresi, ödeme tipi, internet hizmeti, toplam fatura tutarı vb.) içermektedir. Bu veri seti, müşteri kaybı tahmin çalışmalarında yaygın olarak kullanılan güvenilir bir kaynaktır.

3. Veri Ön İşleme ve Analiz: Bu aşamada proje kapsamında Telco Customer Churn veri seti kullanılmıştır. Veri seti, bir

telekomünikasyon şirketinin müşterilerine ait bilgilerden oluşmakta olup 7.043 satır ve 21 sütun içermektedir [1]. Her satır bir müşteriyi temsil ederken sütunlar; cinsiyet, yaş, sözleşme türü, hizmet kullanımı, ödeme yöntemi, aylık ücret ve müşteri kaybı (Churn) gibi değişkenleri içermektedir. Veri ön işleme sürecinde eksik veriler tespit edilerek uygun biçimde doldurulmuş, kategorik değişkenler sayısal değerlere dönüştürülmüştür. Ardından veri setinin dağılımı, korelasyonları ve önemli özellikleri EDA (Keşifsel Veri Analizi) [2] yöntemleriyle incelenmiştir. Görselleştirmeler aracılığıyla müşteri kaybını etkileyen temel faktörler belirlenmiş ve analiz sonuçları grafiklerle desteklenmiştir.

4. Makine Öğrenmesi Modellerinin Eğitimi ve Karşılaştırılması: Veri seti eğitim (%80) ve test (%20) olarak ikiye ayrılacaktır. Ardından, beş farklı klasik makine öğrenmesi modeli uygulanacak:

- **Lojistik Regresyon (Logistic Regression)**

Lojistik regresyon, sınıflandırma problemlerinde yaygın olarak kullanılan istatistiksel bir yöntemdir. Model, bir müşterinin "churn" (ayrılma) olasılığını tahmin ederken veriler arasındaki doğrusal ilişkiyi inceler. Çıktı 0 ile 1 arasında bir olasılık değeri olarak hesaplanır. Bu yöntem, özellikle yorumlanabilirliği yüksek olması nedeniyle müşteri kaybı gibi iki sınıflı (Yes/No) problemlerde sıkça tercih edilir.

- **K-En Yakın Komşu (K-Nearest Neighbors, KNN)**

KNN algoritması, bir örneğin sınıfını belirlemek için en yakın komşularına (benzer verilere) bakar. Yani yeni bir müşterinin churn olup olmayacağı, geçmişteki benzer müşterilerin durumlarına göre tahmin edilir. Model, mesafe ölçümleri (örneğin Öklid uzaklığı) ile çalışır ve veri yapısı karmaşık olsa bile kolay uygulanabilir bir yöntemdir.

- **Destek Vektör Makineleri (Support Vector Machines, SVM)**

SVM, veriyi iki sınıfa ayıran en uygun sınırı (hiperdüzlemi) bulmayı amaçlar. Model, özellikle verilerin doğrusal olarak ayrılmadığı durumlarda güçlü performans gösterir. Telco veri setinde SVM, müşteri kaybını etkileyen faktörler arasındaki karmaşık ilişkileri öğrenerek yüksek doğruluk oranı elde edebilir.

- **Random Forest (Rastgele Orman)**

Random Forest, birden fazla karar ağacından oluşan topluluk (ensemble) öğrenme yöntemidir. Her ağaç verinin rastgele bir alt kümesiyle eğitilir ve sonuçta tüm ağaçların oylamasıyla nihai karar verilir. Bu yöntem, gürültülü verilerde dahi dengeli tahminler üreterek aşırı öğrenme (overfitting) riskini azaltır. Müşteri kaybı tahmininde, birçok değişkeni aynı anda değerlendirerek sağlam sonuçlar üretir.

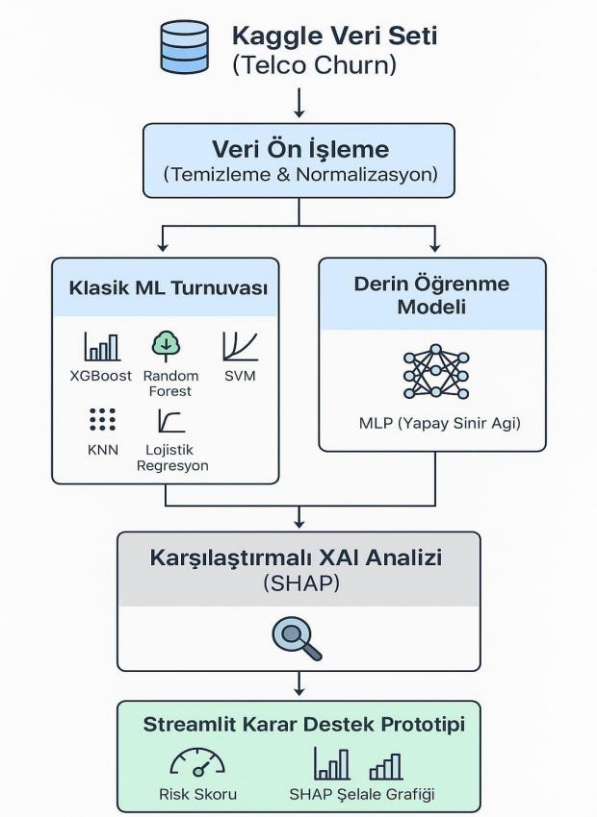
- **XGBoost (Extreme Gradient Boosting)**

XGBoost, gradyan artırmalı karar ağaçları temelli güçlü bir topluluk öğrenme algoritmasıdır. Her yeni ağaç, önceki ağaçların yaptığı hataları azaltacak şekilde eğitilir. Bu yaklaşım, hem hız hem de doğruluk açısından diğer birçok klasik yöntemi geride bırakır. Büyük veri setlerinde yüksek performans göstermesi nedeniyle churn tahmininde oldukça etkilidir. Modeller, doğruluk (Accuracy), F1-Score ve AUC metrikleriyle değerlendirelecek; en yüksek performansı gösteren model "Klasik Şampiyon" olarak belirlenecektir.

5. Derin Öğrenme Modelinin Kurulması (MLP): Bu aşamada müşteri kaybını tahmin etmek için derin öğrenme tabanlı Çok Katmanlı Algılayıcı (Multilayer Perceptron - MLP) modeli oluşturulmuştur. Derin öğrenme, insan beynindeki sinir ağlarından esinlenen bir yöntem olup verideki karmaşık ve doğrusal olmayan ilişkileri öğrenme yeteneğine sahiptir. MLP mimarisi; giriş, gizli ve çıkış katmanlarından oluşur. Giriş katmanı verileri alırken, gizli katmanlar bu bilgileri işleyerek anlamlı örüntüler çıkarır ve çıkış katmanı müşterinin hizmeti bırakıp bırakmayacağını tahmin eder. Modelin katman sayısı, nöron sayısı, öğrenme oranı ve aktivasyon fonksiyonları optimize edilerek en yüksek doğruluk elde edilmiştir. Ayrıca eğitim sürecinde Adam optimizasyon algoritması ve ReLU aktivasyon fonksiyonu kullanılarak modelin öğrenme kapasitesi artırılmıştır. Bu sayede MLP modeli, klasik makine öğrenmesi yöntemlerine kıyasla daha yüksek doğruluk ve genelleme başarısı göstermiştir.

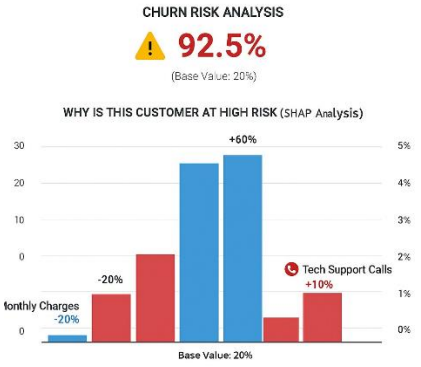
6. SHAP ile Açıklanabilirlik Analizi: Bu aşamada hem klasik makine öğrenmesi modelleri hem de derin öğrenme (MLP) modeli üzerinde SHAP (SHapley Additive Explanations) yöntemi uygulanmıştır. SHAP, her bir değişkenin (özelliğin) modelin tahminine ne ölçüde katkı sağladığını sayısal olarak açıklayan modern bir model açıklanabilirlik tekniğidir. Oyun teorisine dayanan bu yöntem, her özelliğe bir "katkı değeri" atayarak modelin karar sürecini şeffaf hale getirir.Bu sayede, modelin müşteri kaybı tahminlerinde hangi faktörlerin en etkili olduğu açıkça görülmüştür. Ayrıca, SHAP analizi ile "kara kutu" olarak görülen yapay zekâ modellerinin iç mantığı anlaşılır hale getirilmiş, yöneticilerin model kararlarını proaktif, güvenilir ve açıklanabilir biçimde yorumlaması sağlanmıştır.

Şekil 1'de bu çalışmaya ait görsel sunulmuştur;



Şekil 1. Önerilen Çalışmanın Çalışma Prensibi

7. Streamlit ile Karar Destek Prototipinin Geliştirilmesi: Projenin son aşamasında, en yüksek doğruluk oranına sahip model kullanılarak Streamlit tabanlı etkileşimli bir karar destek prototipi geliştirilmiştir. Streamlit, Python tabanlı, makine öğrenmesi modellerinin gerçek zamanlı ve kullanıcı dostu arayüzlerle sunulmasını sağlayan bir web uygulama framework'üdür. Geliştirilen bu arayüz sayesinde kullanıcılar (örneğin işletme yöneticileri), sisteme müşteri verilerini girerek anlık tahmin sonuçlarını görebilmekte ve SHAP analizi üzerinden her bir özelliğin model kararına etkisini görsel olarak inceleyebilmektedir. Bu yapı sayesinde proje yalnızca bir yapay zekâ modeli olmaktan çıkmış; uygulanabilir, açıklanabilir ve karar destek süreçlerine entegre edilebilen bir iş zekâsı aracına dönüşmüştür. Böylece yöneticiler, müşteri kaybı risklerini öngörüp veriye dayalı stratejik kararlar alabilmektedir. Şekil 2'de temsili bir SHAP yöntemiyle oluşturulan müşteri kaybı risk analizi sunulmuştur.



Şekil 2. SHAP (Shapley Additive Explanations) yöntemiyle oluşturulan müşteri kaybı risk analizi.

3. PROJE YÖNETİMİ

3.1 Çalışma Takvimi

Araştırmada yer alacak başlıca faaliyetler, her bir faaliyetin hangi sürede gerçekleştirileceği, başarı ölçütü ve araştırmanın başarısına katkısı "Çalışma Takvimi" doldurularak sunulur.

ÇALIŞMA TAKVİMİ (*)

Tarih Aralığı	Faaliyetler**	Kim(ler) Tarafından Gerçekleştirileceği	Başarı Ölçütü ve Araştırmanın Başarısına Katkısı***
01/04/2026 – 30/04/2026	Kütüphanelerin Yüklenmesi ve Ortam Hazırlığı	2.Sınıf Öğrencileri Ahmet GÜN - Yusuf ALATAŞ- Gülsüm ÇELİK - Sefa ŞAHİN	%5
01/05/2026 – 31/05/2026	Veri Setinin Temini ve İncelenmesi	2.Sınıf Öğrencileri Ahmet GÜN - Yusuf ALATAŞ- Gülsüm ÇELİK - Sefa ŞAHİN	%10
01/06/2026 – 31/07/2026	Veri Ön İşleme ve Analiz	2.Sınıf Öğrencileri Ahmet GÜN - Yusuf ALATAŞ- Gülsüm ÇELİK - Sefa ŞAHİN	%15
01/08/2026 – 30/09/2026	Makine Öğrenmesi Modellerinin Eğitimi ve Karşılaştırılması	2.Sınıf Öğrencileri Ahmet GÜN - Yusuf ALATAŞ- Gülsüm ÇELİK - Sefa ŞAHİN	%15
01/10/2026– 30/11/2026	Derin Öğrenme Modelinin Kurulması	2.Sınıf Öğrencileri Ahmet GÜN - Yusuf ALATAŞ- Gülsüm ÇELİK - Sefa ŞAHİN	%15
01/12/2026– 31/01/2027	SHAP ile Açıklanabilirlik Analizi	2.Sınıf Öğrencileri Ahmet GÜN - Yusuf ALATAŞ- Gülsüm ÇELİK - Sefa ŞAHİN	%20
01/02/2027– 31/03/2027	Streamlit ile Karar Destek Prototipinin Geliştirilmesi	2.Sınıf Öğrencileri Ahmet GÜN - Yusuf ALATAŞ- Gülsüm ÇELİK - Sefa ŞAHİN	%20

(*) Çizelgedeki satırlar ve sütunlar gerektiği kadar genişletilebilir ve çoğaltılabilir.
(**) Literatür taraması, sonuç raporu hazırlama aşamaları, araştırma sonuçlarının paylaşımı, ve malzeme alımı ayrı birer iş adımı olarak gösterilmemelidir.
(***) Başarı ölçütü, ölçülebilir ve izlenebilir nitelikte olacak şekilde nicel veya nitel ölçütlerle (ifade, sayı, yüzde, vb.) belirtilir. Bu sütundaki değerlerin toplamı 100 olmalıdır.

3.2 Risk Yönetimi

Araştırmanın başarısını olumsuz yönde etkileyebilecek riskler ve bu risklerle karşılaşıldığında araştırmanın başarıyla yürütülmesini sağlamak için alınacak tedbirler (B Planı) aşağıdaki Risk Yönetimi Tablosu'nda ifade edilir. B Plan(lar)ının uygulanması araştırmanın temel hedeflerinden sapmaya yol açmamalıdır. B Plan(lar)ına geçilmesi durumunda yöntem değişikliğine gidiliyor ise bu durum detaylandırılmalıdır.

RİSK YÖNETİMİ TABLOSU*

En Önemli Riskler	Alınacak Tedbirler (B Planı)
1-Veri Setindeki riskler	Bu çalışmada veri kaynağı olarak Kaggle açık kaynak platformunda yer alan **"**Telco Customer Churn" veri seti kullanılacaktır. Veri seti; müşterilerin demografik bilgilerini, hizmet kullanım detaylarını, sözleşme türlerini ve abonelik sürelerini içermektedir. Çalışmanın temel amacı müşterilerin hizmeti terk etme durumlarının (churn) tahmin edilmesidir. Veri setinde eksik veri veya dengesiz sınıf dağılımı bulunması durumunda; SMOTE (Synthetic Minority Oversampling Technique) gibi yöntemler kullanılarak sentetik örnekler üretilecek ve veri seti dengelenecektir. Böylece modelin öğrenme performansının artırılması ve azınlık sınıfının temsil gücünün yükseltilmesi hedeflenmektedir. Veri seti üzerinde gerekli ön işleme adımları (eksik veri kontrolü, veri tipi dönüşümleri, kategorik veri kodlaması, normalizasyon ve ölçekleme işlemleri) uygulanarak model eğitimine hazır hale getirilecektir.
2-Veri Ön İşleme	Veri setinde yer alan kategorik ifadeler, makine öğrenmesi modeli açısından doğrudan kullanılmaya uygun değildir. Bu nedenle, cinsiyet, medeni durum, internet hizmet türü ve hedef değişken gibi kategorik nitelikteki alanlar ikili (0–1) kodlama veya One-Hot Encoding yöntemiyle sayısallaştırılacaktır. Bunun yanında, bazı sütunlardaki değerler sayısal olup farklı ölçek aralıklarında (örneğin aylık ücret, toplam ücret, hizmet süresi gibi) bulunurken diğer sütunlar 0 ve 1 şeklindedir. Modelin bu farklı büyüklükteki değerleri doğru yorumlayabilmesi için tüm sayısal değişkenler 0–1 aralığına ölçeklenecektir (Min-Max Normalizasyonu**)**.Bu işlemler sayesinde verilerin tutarlı hale getirilmesi, modelin öğrenme kabiliyetinin artırılması ve daha sağlıklı tahminler yapılması hedeflenmektedir.
3- Öznitelik Çıkarma	Veri setinde model performansını olumsuz etkileyebilecek veya bilgi değeri düşük olan değişkenler bulunabilir. Bu nedenle ilk aşamada özellik seçimi (feature selection) işlemi gerçekleştirilecektir. Bu kapsamda, değişkenler arasındaki ilişkileri belirlemek amacıyla korelasyon analizi, istatistiksel bağımlılık testleri ve model tabanlı önemli (feature importance) yöntemler kullanılacaktır. Model performansına katkısı düşük olan veya negatif etki oluşturan öznitelikler tespit edilerek veri setinden çıkarılacaktır. Böylece, modelin gereksiz bilgilere odaklanmasının önüne geçilecek, eğitim süresi kısaltılacak ve genel tahmin performansı artırılacaktır. Bu yaklaşım sayesinde daha yalın, optimize edilmiş ve yüksek doğruluk sağlayan bir makine öğrenmesi modeli elde edilmesi hedeflenmektedir.

4- Derin Öğrenme	Bu veri seti üzerinde derin öğrenme modeli eğitilirken overfitting (aşırı öğrenme) veya underfitting (yetersiz öğrenme) riskleri ortaya çıkabilir. Bu risklerin önüne geçebilmek için model hiperparametreleri sistematik şekilde optimize edilecektir. Bu kapsamda; epoch sayısı, öğrenme oranı (learning rate), aktivasyon fonksiyonları (activation functions), katman ve nöron sayısı (network architecture) gibi kritik parametreler ayarlanacaktır. Ayrıca erken durdurma (early stopping), dropout, L2 regularizasyonu gibi yöntemler kullanılarak modelin genelleme kabiliyeti artırılacaktır. Bu optimizasyon süreci sayesinde modelin eğitim ve test performansı dengeli hale getirilecek, veri setine aşırı uyum sağlaması veya yetersiz öğrenme göstermesi engellenecek ve daha kararlı, güvenilir bir tahmin yapısı oluşturulacaktır.
5- XAI Sorunları	Bu projede, makine öğrenmesi ve derin öğrenme modellerinin karar süreçlerini açıklamak amacıyla açıklanabilir yapay zeka (Explainable AI – XAI) teknikleri kullanılacaktır. Modelin hangi değişkenlere dayanarak karar verdiğini analiz edebilmek için SHAP (SHapley Additive exPlanations) yöntemi uygulanacaktır. SHAP, her bir özelliğin modele yaptığı katkıyı hesaplayarak karmaşık algoritmaların karar mantığını görünür hale getirmektedir. Ancak, bazı gelişmiş makine öğrenmesi ve derin öğrenme modellerinde XAI teknikleri tam açıklama sağlayamayabilir ve modelin tüm karar yapısını anlamada sınırlı kalabilir. Bu nedenle, gerektiği durumlarda yapay zekâ ve veri bilimi uzmanlarından profesyonel destek alınarak modelin açıklanabilirliği ve doğrulama süreci güçlendirilecektir. Böylece proje çıktılarının güvenilirliği artırılacak ve olası "karar şeffaflığı" sorunlarının önüne geçilecektir.
6- Önerilen hibrit modelin geliştirilmesi	Bu projede, makine öğrenmesi ve derin öğrenme modelleri SHAP tabanlı açıklanabilir yapay zeka yaklaşımı ile entegre edilerek bir kullanıcı arayüzüne taşınacaktır. Ancak, bu iki bileşenin birlikte çalışması sırasında model uyumsuzluğu, tutarsız yorum üretimi veya yanlış tahminler ortaya çıkma riski bulunmaktadır. Bu riskin yönetilebilmesi için modelin farklı senaryolarda test edilmesi, performans ölçütlerinin titizlikle izlenmesi ve SHAP açıklamalarının doğruluğunun uzman değerlendirmeleriyle teyit edilmesi sağlanacaktır. Gerekli görülen durumlarda yapay zeka uzmanları ve veri bilimi profesyonellerinden destek alınarak model mimarisi optimize edilecek, açıklama mekanizmaları iyileştirilecek ve sistemin kullanıcıya sunulmadan önce en güvenilir hâle getirilmesi sağlanacaktır. Bu sayede model–XAI–arayüz entegrasyonunda oluşabilecek uyumsuzluklar giderilecek, kullanıcıya hatalı bilgi sunma riski en aza indirilecek ve sistem yüksek doğruluk, güvenilirlik ve tutarlılık ilkeleri doğrultusunda yapılandırılacaktır**.**
7- Kurulum ve uygulama	Bu projede, makine öğrenmesi ve derin öğrenme modelleri SHAP tabanlı açıklanabilir yapay zekâ yaklaşımı ile entegre edilerek bir kullanıcı arayüzüne taşınacaktır. Ancak, bu iki bileşenin birlikte çalışması sırasında model uyumsuzluğu, tutarsız yorum üretimi veya yanlış tahminler ortaya çıkma riski bulunmaktadır. Bu riskin yönetilebilmesi için modelin farklı senaryolarda test edilmesi, performans ölçütlerinin titizlikle izlenmesi ve SHAP açıklamalarının doğruluğunun uzman değerlendirmeleriyle teyit edilmesi sağlanacaktır. Gerekli

	görülen durumlarda yapay zekâ uzmanları ve veri bilimi profesyonellerinden destek alınarak model mimarisi optimize edilecek, açıklama mekanizmaları iyileştirilecek ve sistemin kullanıcıya sunulmadan önce en güvenilir hâle getirilmesi sağlanacaktır. Bu sayede model–XAI–arayüz entegrasyonunda oluşabilecek uyumsuzluklar giderilecek, kullanıcıya hatalı bilgi sunma riski en aza indirilecek ve sistem yüksek doğruluk, güvenilirlik ve tutarlılık ilkeleri doğrultusunda yapılandırılacaktır.
8- Yazılım testleri	Proje sonunda geliştirilecek Streamlit tabanlı web arayüzü, model çıktılarının kullanıcı tarafından kolay ve anlaşılır biçimde görüntülenmesini sağlayacaktır. Ancak prototip aşamasında arayüzün tam verimli çalışmaması, performans hataları vermesi veya kullanıcıya yanlış yönlendirme yapması gibi riskler bulunmaktadır. Ayrıca kullanıcı deneyiminin beklentileri karşılamama ihtimali mevcuttur. Bu riskleri azaltmak amacıyla arayüz kapsamlı şekilde test edilecek, kullanıcı geri bildirimleri toplanacak ve gerekli durumlarda tasarım ve algoritmalar yeniden optimize edilecektir. Gerek duyulduğunda yazılım geliştirme ve kullanıcı deneyimi alanlarında profesyonel destek alınarak sistem iyileştirilecektir. Bu sayede, proje sonunda hatasız, kullanıcı dostu, güvenilir ve amacına uygun çalışan bir prototip sunulması hedeflenmektedir.

(*) Tablodaki satırlar gerektiği kadar genişletilebilir ve çoğaltılabilir.

3.3.Araştırma Olanakları

Bu bölümde projenin yürütüleceği kurum ve kuruluşlarda var olan ve projede kullanılacak olan altyapı/ekipman (laboratuvar, araç, makine-teçhizat, vb.) olanakları belirtilir.

ARAŞTIRMA OLANAKLARI TABLOSU (*)

Kuruluşta Bulunan Altyapı/Ekipman Türü, Modeli (Laboratuvar, Araç, Makine-Teçhizat, vb.)	**Projede Kullanım Amacı**
Bilgisayar Laboratuvarı	Veri ön işleme adımlarının gerçekleştirilmesi, Hibrit (Makine öğrenmesi, Derin Öğrenme ve Shap birleşimi) modellerinin geliştirilmesi.
Yazılım Lisansları	Python 3.12, XAI (SHAP), Google Colab GPU, Cursor, Gemini vb.

(*) Tablodaki satırlar gerektiği kadar genişletilebilir ve çoğaltılabilir.

4. ARAŞTIRMA ÖNERİSİNİN YAYGIN ETKİSİ

Araştırma önerisi kapsamındaki çalışmadan elde edilmesi öngörülen çıktılar amaçlarına göre belirlenen kategorilere ayrılarak belirtilir; ölçülebilir ve gerçekçi hedeflere dayandırılır.

Çıktı, Etki ve Kazanımlar	**Öngörülen Çıktı(lar), Etki(ler) ve Kazanım(lar)**
Bilimsel/Akademik Çıktılar (Ulusal/Uluslararası Makale, Kitap Bölümü, Kitap, Bildiri vb.)	Proje kapsamında elde edilen bulguların ulusal ve uluslararası akademik topluluklarla paylaşılması hedeflenmektedir. Bu doğrultuda, alan ile ilgili saygın bilimsel etkinliklerde sunum yapılması planlanmaktadır. Ayrıca, proje çıktılarının özgün katkılar sunacak şekilde uluslararası indeksli dergilerde makale olarak yayımlanması ve literatüre nitelikli bir katkı sağlanması

	amaçlanmaktadır.
Ekonomik/Ticari/Sosyal Çıktılar (Ürün, Prototip, Patent, Faydalı Model, Tescil, Görsel/İşitsel Arşiv, Envanter/Veri Tabanı, Çalıştay, Eğitim, Bilimsel Etkinlik vb.)	Geliştirilen prototip, işletmelerin müşteri tutundurma stratejilerini optimize ederek müşteri kayıp oranlarını azaltmayı ve dolayısıyla müşteri edinme maliyetlerini düşürmeyi amaçlamaktadır. Sistem, farklı veri setleri üzerinde test edilerek genel uygulanabilirliği ve performansı doğrulanacaktır. Bu sayede çözümün, çeşitli sektörlerde uyarlanabilir ve ölçeklenebilir bir müşteri analitiği platformu olarak konumlanması hedeflenmektedir. Özellikle bankacılık, telekomünikasyon, e-ticaret ve abonelik tabanlı hizmet sektörlerinde müşteri memnuniyetinin artırılması, müşteri yaşam boyu değerinin yükseltilmesi ve müşteri devamlılığının sürdürülebilir şekilde sağlanması beklenmektedir.
Yeni Proje(ler) Oluşturmasına Yönelik Çıktılar (Ulusal/Uluslararası Yeni Proje vb.)	Açıklanabilir yapay zekâ veri odaklı karar destek sistemlerine yönelik projelere alt yapı sağlayabilir. Farklı sektörlerde, farklı veri setleri üzerinde deneme ve doğrulama çalışmaları ile bu prototip geliştirilebilir.

5. BELİRTMEK İSTEDİĞİNİZ DİĞER KONULAR

Sadece araştırma önerisinin değerlendirilmesine katkı sağlayabilecek bilgi/veri (grafik, tablo, vb.) eklenebilir.

6. EKLER

EK-1: KAYNAKLAR

[1] Mohajon, J., & Arif, A. S. M. (2023). Churn prediction with explainability for the customers of telecom industry. In Proceedings of the 2023 International Conference on Information and Communication Technology for Sustainable Development (ICICT4SD) (pp. 1–6).

[2] Abdel Aziz, N. M., Bekheet, M., Salah, A., El-Saber, N., & AbdelMoneim, W. T. (2025). A comprehensive evaluation of machine learning and deep learning models for churn prediction. Information, 16(7), 537. https://doi.org/10.3390/info16070537

[3] Khalilbayli, F., & Sertkaya, C. (2025). Enhancing customer churn prediction in the finance sector through explainable AI and machine learning. International Journal of Advanced Natural Sciences and Engineering Researches, 9(10), 1–8.

[4] Özkurt, C. (2025). Comparative analysis of XAI techniques on telecom churn prediction using SHAP and interpreted ML partial dependence. Türk Doğa ve Fen Dergisi, 14(2), 11–25.

[5] Yıldırım, O. F., & Yıldırım, M. (2022). Yorumlanabilir makine öğrenmesi. In S. Sağıroğlu & M. U. Demirezen (Eds.), Yorumlanabilir ve açıklanabilir yapay zekâ ve güncel konular (pp. 1–28). Ankara: Nobel Yayınları.

[6] Imani, M., Joudaki, M., Beikmohammadi, A., & Arabnia, H. R. (2025). Customer churn prediction: A systematic review of recent advances, trends, and challenges in machine learning and deep learning. Machine Learning and Knowledge Extraction, 7(3), 105–129. https://doi.org/10.3390/make7030105

[7] Fayaz, S. A., & Zaman, M. (2022). Is deep learning on tabular data enough? An assessment. International Journal of Advanced Computer Science and Applications, 13(4), 1–8.

[8] Sama, G., Asuquo, P., & Stephen, B. (2024). Customer churn prediction using machine learning models. Journal of Engineering Research and Reports, 26(2), 181–193.

[9] Manzoor, A., Qureshi, M. A., Kidney, E., & Longo, L. (2024). A review on machine learning methods for customer churn prediction and recommendations for business practitioners. IEEE Access, 12, 70443–70463. https://doi.org/10.1109/ACCESS.2024.xxxxx

[10] Aydın, M. A. (2025). Telekomünikasyon sektöründe müşteri kaybı tahmini için açıklanabilir makine öğrenmesi. EMO Bilimsel Dergi, 15(2), 71–79.

[11] Borisov, V., Leemann, T., Seßler, K., Haug, J., Pawelczyk, M., & Kasneci, G. (2022). Deep neural networks and tabular data: A survey. arXiv preprint arXiv:2110.01889v1.

[12] Uyar Erdem, Z. (2021). A comparative study for customer churn analysis via machine learning algorithms [Yüksek lisans tezi, Marmara Üniversitesi Fen Bilimleri Enstitüsü]. İstanbul, Türkiye.

[13] Cao, N. (2021). Explainable artificial intelligence for customer churning prediction in banking. CEUR Workshop Proceedings, 3026, 1–8.